Comparación de algoritmos de clustering: K-Means, DBSCAN y clustering jerárquico

Informe Técnico

Casos: Wine, Make Moons e Iris - Scikit-learn

Brayan Yesid Vega Niño

Repositorio GitHub: https://github.com/bravegn-arch/Guia_Semana_11_Clustering

Introducción A Machine Learning CAD2092023103

Universidad de Cundinamarca

Especialización en Analítica y Ciencia de Datos

5 de noviembre de 2026

Tabla de Contenido

1. Resumen....3
2. Datos....3
2.1 Wine (K-Means)....4
2.2 Make Moons (DBSCAN)....4
2.3 Iris (clustering jerárquico)....4
3. Métodos de clustering....5
3.1 K-Means....5
3.2 DBSCAN....5
3.3 Clustering jerárquico aglomerativo....5
3.4 Métricas de evaluación....6
4. Resultados....6
4.1 K-Means sobre Wine....6
4.2 DBSCAN sobre Make Moons....10
4.3 Clustering jerárquico sobre Iris....13
4.4 Comparación de los algoritmos....16
5. Análisis y discusión....17
5.1 K-Means (Wine)....17
5.2 DBSCAN (Make Moons)....18
5.3 Clustering jerárquico (Iris)....19
5.4 ¿En qué tipo de problema se usaría cada algoritmo?....20
5.5 Limitaciones generales....21
6. Conclusiones....21
7. Repositorio GitHub....22
8. Referencias....22
9. Anexos....25
Anexo A. Fragmentos de código clave....25
Anexo B. Resultados extendidos....27

1. Resumen

Este informe documenta la aplicación de tres algoritmos de clustering (K-Means, DBSCAN y clustering jerárquico aglomerativo) sobre los conjuntos Wine, Make Moons e Iris de Scikit-learn, con el fin de justificar el algoritmo, los hiperparámetros y el número de grupos en cada caso y evaluar los resultados con Silhouette, Davies-Bouldin y Calinski-Harabasz. Las etiquetas conocidas no se usaron para construir los clusters. En Wine, el método del codo y las tres métricas coinciden en K = 3 (Silhouette = 0,285), con grupos que se distinguen por flavonoides, prolina y color y que coinciden con los cultivares reales en 172 de 178 muestras. En Make Moons, DBSCAN con eps = 0,30 y min_samples = 5 recupera exactamente las dos lunas, mientras que K-Means las corta pese a obtener mejores métricas internas. En Iris, el dendrograma y las métricas apuntan a dos clusters (Silhouette = 0,577). Se concluye que el algoritmo debe elegirse según la forma de los grupos, el ruido y el tamaño de los datos, y que las métricas internas deben complementarse con visualización y criterio del dominio.

Palabras clave: clustering, K-Means, DBSCAN, clustering jerárquico, validación interna, PCA

2. Datos

Se emplearon tres conjuntos de datos, uno por algoritmo, todos disponibles en Scikit-learn (Pedregosa et al., 2011), de modo que el análisis es reproducible. Cuando un conjunto trae etiquetas conocidas, estas se separaron de las variables predictoras y solo se usaron después, como referencia, mediante el Índice de Rand ajustado (ARI; Hubert & Arabie, 1985). La Tabla 1 resume los conjuntos y el preprocesamiento aplicado.

Tabla 1
Descripción de los conjuntos de datos y preprocesamiento

Conjunto	Fuente	Registros	Variables	Preprocesamiento
Wine	load_wine(); Forina et al. (1991)	178	13 numéricas continuas	Sin nulos; StandardScaler; target excluido
Make Moons	make_moons(); n = 500, noise = 0,07, random_state = 42	500	2 numéricas continuas (x1, x2)	StandardScaler; etiqueta de luna excluida
Iris	load_iris(); Fisher (1936)	150	4 numéricas continuas (cm)	Sin nulos; StandardScaler; especie excluida

Nota. Elaboración propia a partir de los resultados del notebook.

2.1 Wine (K-Means)

El conjunto Wine contiene 178 muestras de vino descritas por 13 variables físico-químicas de tipo `float64`: alcohol, ácido málico, ceniza, alcalinidad de la ceniza, magnesio, fenoles totales, flavonoides, fenoles no flavonoides, proantocianinas, intensidad de color, matiz, OD280/OD315 y prolina. No hay valores nulos. Las escalas son muy heterogéneas: la prolina varía entre 278 y 1.680 (desviación estándar de 314,9), mientras que los fenoles no flavonoides varían entre 0,13 y 0,66 (desviación estándar de 0,12), una razón de unas 2.600 veces. Como K-Means usa distancia euclidiana, se aplicó `StandardScaler` para que las 13 variables aportaran de forma comparable. La variable `target` (tres cultivares de 59, 71 y 48 muestras) no se utilizó para construir los clusters.

2.2 Make Moons (DBSCAN)

Se generaron 500 observaciones con `make_moons(n_samples=500, noise=0.07, random_state=42)`: dos semicírculos entrelazados de 250 puntos cada uno, descritos por dos variables (x1, x2). Los datos se estandarizaron para que `eps` tenga el mismo significado en ambas variables. La forma es no convexa: el centro de cada luna cae en una zona vacía y más cerca de la otra luna (Figura 4).

2.3 Iris (clustering jerárquico)

Iris contiene 150 flores descritas por cuatro medidas en centímetros (largo y ancho de sépalo y de pétalo), sin valores nulos, de tres especies de 50 flores cada una que no se usaron para agrupar. Aunque las variables comparten unidad, la desviación estándar del largo del pétalo (1,77) es unas cuatro veces la del ancho del sépalo (0,44), por lo que también se estandarizaron.

3. Métodos de clustering

Se aplicó un algoritmo por conjunto de datos, elegido por su afinidad con la estructura esperada: K-Means (centroides) para Wine, DBSCAN (densidad) para Make Moons y clustering jerárquico aglomerativo para Iris. Todos usan distancia euclidiana sobre datos estandarizados y una semilla fija (`random_state = 42`).

3.1 K-Means

K-Means (MacQueen, 1967) asigna cada observación al centroide más cercano y recalcula los centroides hasta converger, minimizando la inercia, es decir, la suma de las distancias al cuadrado a los centroides. Su hiperparámetro principal es K. Se evaluaron K = 2 a 10 (el mínimo exigido era 2 a 6) y se usó `n_init = 10`, de modo que cada ejecución conserva la mejor de diez inicializaciones.

3.2 DBSCAN

DBSCAN (Ester et al., 1996) define un cluster como una región conexa de alta densidad: un punto es central si tiene al menos `min_samples` vecinos (incluido él mismo) a una distancia menor o igual que `eps`; los puntos alcanzables desde uno central se agregan al cluster y los demás se etiquetan como ruido (-1). Se probaron 12 combinaciones de `eps` (0,05 a 1,00) y `min_samples` (3, 5, 10 y 20); el gráfico de k-distancias (Anexo B) orientó la escala de `eps`.

3.3 Clustering jerárquico aglomerativo

El método parte de cada observación como un grupo y fusiona sucesivamente los dos grupos más cercanos. Se usó el enlace de Ward (Ward, 1963), que en cada paso fusiona los grupos que menos aumentan la varianza interna. El resultado se resume en un dendrograma construido con SciPy (Virtanen et al., 2020), cuyo eje vertical es la distancia de fusión; el número de clusters se decide cortándolo a una altura dada y luego se aplica `AgglomerativeClustering` con ese número.

3.4 Métricas de evaluación

Se calcularon tres métricas internas, que no requieren etiquetas: el Silhouette Score (Rousseeuw, 1987), entre -1 y 1, donde valores mayores indican mejor separación; el índice de Davies-Bouldin (Davies & Bouldin, 1979), donde valores menores indican grupos más compactos y separados; y el índice de Calinski-Harabasz (Caliński & Harabasz, 1974), cociente entre la dispersión entre grupos y dentro de ellos, donde valores mayores son mejores. Como referencia opcional, y solo después de construir los clusters, se calculó el ARI frente a la etiqueta conocida. En DBSCAN las métricas se calcularon excluyendo los puntos de ruido y siempre se reportó su porcentaje. PCA con dos componentes se usó exclusivamente para graficar. La Tabla 2 resume los hiperparámetros seleccionados y su justificación.

Tabla 2
Hiperparámetros seleccionados y justificación

Algoritmo	Hiperparámetro	Valor	Justificación
K-Means	K	3	Codo, Silhouette, Davies-Bouldin y Calinski-Harabasz coinciden
	n_init	10	Reduce la dependencia de la inicialización; solución idéntica con 5 semillas
DBSCAN	eps	0,30	Dentro de la zona estable (0,25 a 0,40); el 99 % de los puntos tiene su 5.º vecino a menos de 0,25
	min_samples	5	Valor habitual (al menos dimensiones + 1); con 3 el resultado no cambia y con 20 aparece ruido
Jerárquico	linkage	Ward	Fusiona minimizando el aumento de varianza interna; produce grupos compactos
	n_clusters	2	Salto dominante del dendrograma (14,61) y mejores valores en las tres métricas

Nota. Elaboración propia a partir de los resultados del notebook. Todos los algoritmos usan distancia euclidiana y datos estandarizados.

4. Resultados

4.1 K-Means sobre Wine

La Tabla 3 y la Figura 1 muestran la inercia y las métricas internas para K = 2 a 6; la serie completa hasta K = 10 está en el Anexo B. La inercia disminuye al aumentar K, pero la reducción se desploma después de K = 3: baja 381 al pasar de 2 a 3 clusters y solo 103 al pasar a 4. El Silhouette alcanza su máximo en K = 3 (0,285), donde también se encuentran el máximo de Calinski-Harabasz (70,94) y el mínimo de Davies-Bouldin (1,389).

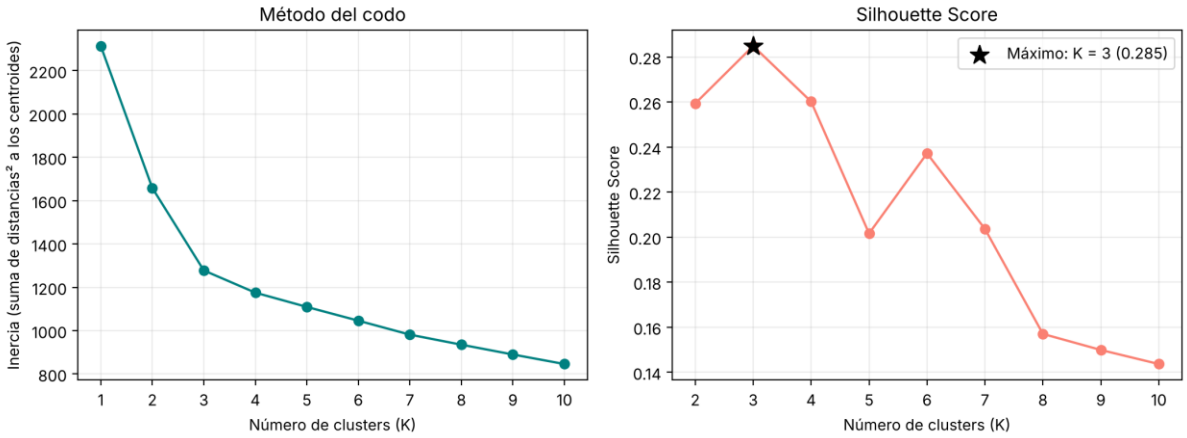
Tabla 3
Inercia y métricas internas de K-Means en Wine según K

K	Inercia	Reducción de inercia	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	1.658,8	655,2	0,259	1,526	69,52
3	**1.277,9**	**380,8**	**0,285**	**1,389**	**70,94**
4	1.175,4	102,5	0,260	1,797	56,18
5	1.109,5	65,9	0,202	1,808	46,95
6	1.046,0	63,5	0,237	1,554	41,70

Nota. En negrita, el valor de K seleccionado. La reducción de inercia es respecto al K anterior. Elaboración propia a partir de los resultados del notebook.

Figura 1

Método del codo y Silhouette Score de K-Means en Wine

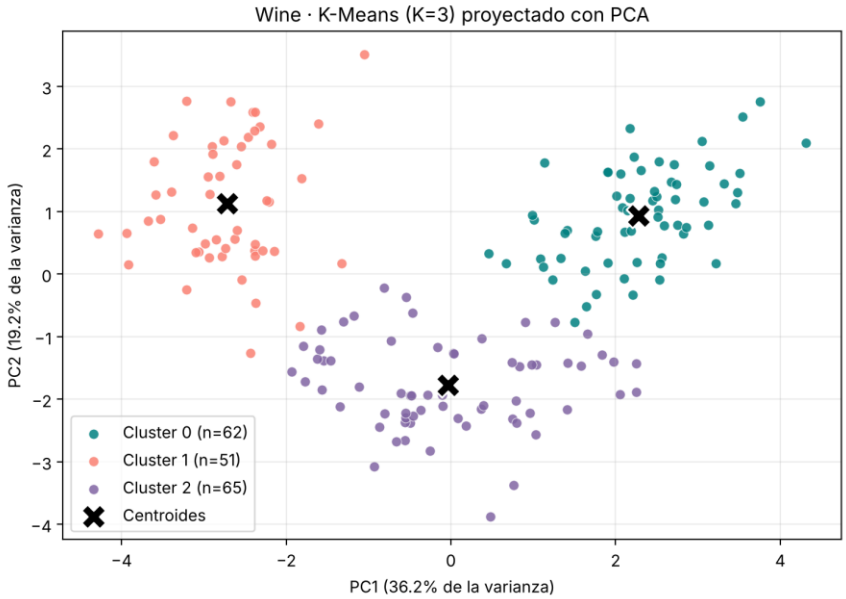


Nota. La estrella marca el máximo del Silhouette (K = 3). Obtenido del notebook.

Con K = 3 se obtuvieron clusters de 62, 51, 65 muestras (Silhouette = 0,285; Davies-Bouldin = 1,389; Calinski-Harabasz = 70,94). La solución fue idéntica con cinco semillas distintas (inercia de 1.277,93). La Figura 2 proyecta los clusters con PCA, cuyos dos componentes explican el 55,4 % de la varianza (36,2 % y 19,2 %).

Figura 2

Clusters de K-Means (K = 3) en Wine proyectados con PCA



Nota. Las X negras son los centroides proyectados. El cluster 0 es el de mayor prolina media. Obtenido del notebook.

La Tabla 4 y la Figura 3 describen los clusters con las variables originales. El cluster 0 concentra los valores altos de prolina, flavonoides, fenoles totales y OD280/OD315; el cluster 1 tiene la mayor intensidad de color y ácido málico con los menores flavonoides, matiz y OD280/OD315; y el cluster 2 tiene el menor alcohol, intensidad de color y prolina.

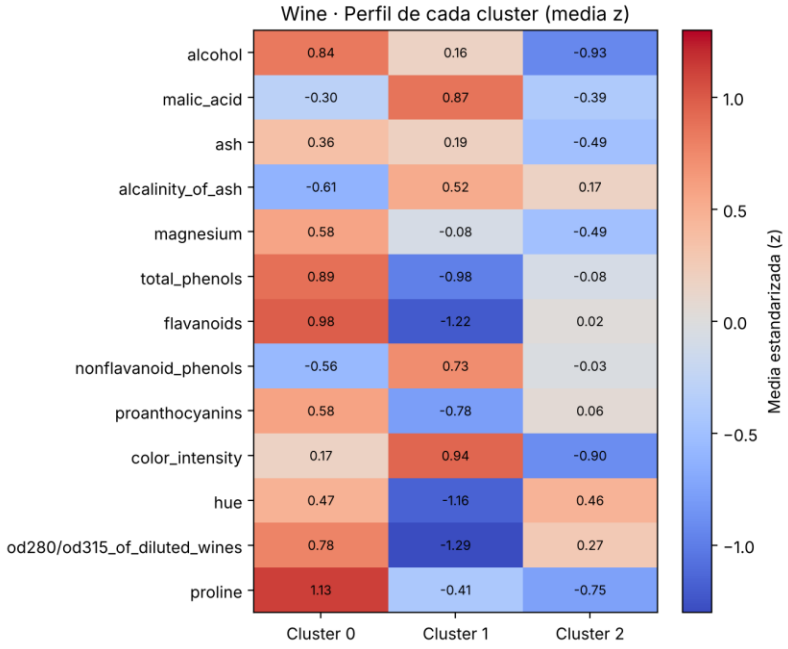
Tabla 4

Media de cada variable original por cluster (K-Means, Wine)

Variable	Cluster 0 (n = 62)	Cluster 1 (n = 51)	Cluster 2 (n = 65)
alcohol	13,68	13,13	12,25
malic_acid	2,00	3,31	1,90
ash	2,47	2,42	2,23
alcalinity_of_ash	17,46	21,24	20,06
magnesium	107,97	98,67	92,74
total_phenols	2,85	1,68	2,25
flavanoids	3,00	0,82	2,05
nonflavanoid_phenols	0,29	0,45	0,36
proanthocyanins	1,92	1,15	1,62
color_intensity	5,45	7,23	2,97
hue	1,07	0,69	1,06
od280/od315_of_diluted_wines	3,16	1,70	2,80
proline	1.100,23	619,06	510,17

Nota. Clusters numerados de mayor a menor prolina media. Elaboración propia a partir de los resultados del notebook.

Figura 3
Perfil estandarizado de cada cluster de Wine



Nota. Cada celda es la media estandarizada (z) de la variable en el cluster; los valores lejos de 0 son las características distintivas. Obtenido del notebook.

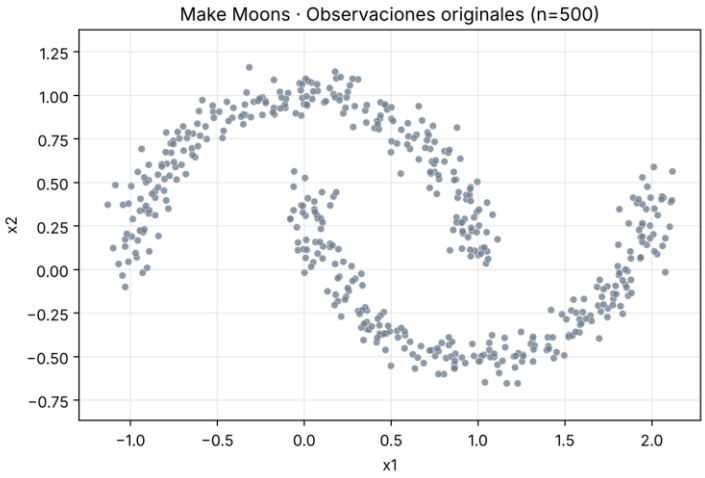
Como contraste opcional con la clase real (que no intervino en la construcción), los clusters coinciden con los tres cultivares en 172 de 178 muestras (ARI = 0,897): solo 6 muestras de la clase 1 quedan en los clusters 0 y 1.

4.2 DBSCAN sobre Make Moons

La Figura 4 muestra los datos antes de agrupar. La Tabla 5 resume las 12 configuraciones probadas y la Figura 5 las muestra gráficamente. Con `eps` muy pequeño (0,05 y 0,10) casi todo se vuelve ruido o se fragmenta en muchos clusters; entre 0,25 y 0,40 aparecen dos clusters sin ruido; y con 0,50 o más las lunas se fusionan en uno solo.

Figura 4

Observaciones originales de Make Moons



Nota. n = 500 puntos, sin colorear por etiqueta. Obtenido del notebook.

Tabla 5

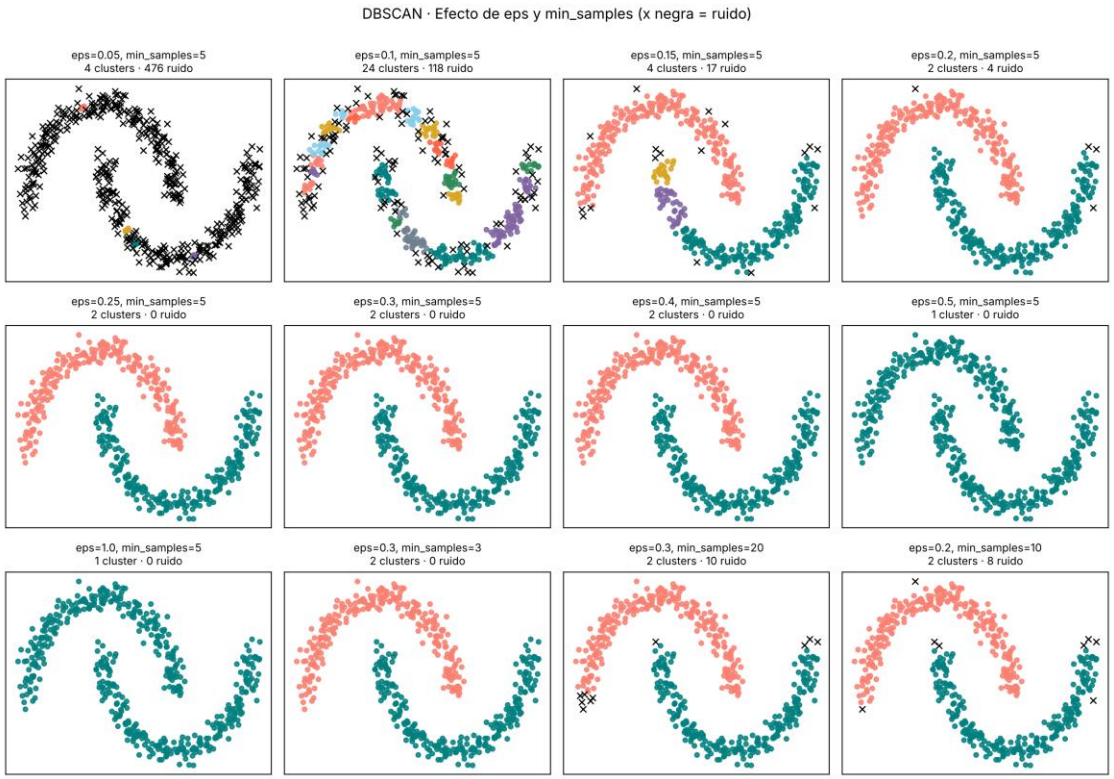
Resultados de DBSCAN para distintas combinaciones de eps y min_samples

eps	min_samples	Clusters	Ruido (n)	Ruido (%)	Silhouette	Davies-Bouldin	Calinski-Harabasz	ARI (ref.)
0,05	5	4	476	95,2	0,907	0,113	11.756,3	0,002
0,10	5	24	118	23,6	0,479	0,543	940,1	0,081
0,15	5	4	17	3,4	0,143	1,336	232,6	0,755
0,20	5	2	4	0,8	0,387	1,018	433,6	0,984
0,25	5	2	0	0,0	0,386	1,022	433,9	1,000
0,30	**5**	**2**	**0**	**0,0**	**0,386**	**1,022**	**433,9**	**1,000**
0,40	5	2	0	0,0	0,386	1,022	433,9	1,000
0,50	5	1	0	0,0	—	—	—	0,000
1,00	5	1	0	0,0	—	—	—	0,000
0,30	3	2	0	0,0	0,386	1,022	433,9	1,000
0,30	20	2	10	2,0	0,397	0,989	453,4	0,960
0,20	10	2	8	1,6	0,395	0,999	446,1	0,968

Nota. En negrita, la configuración seleccionada. Las métricas se calculan sin los puntos de ruido y solo con al menos 2 clusters (— = no definida). El ARI se incluye solo como referencia. Elaboración propia a partir de los resultados del notebook.

Figura 5

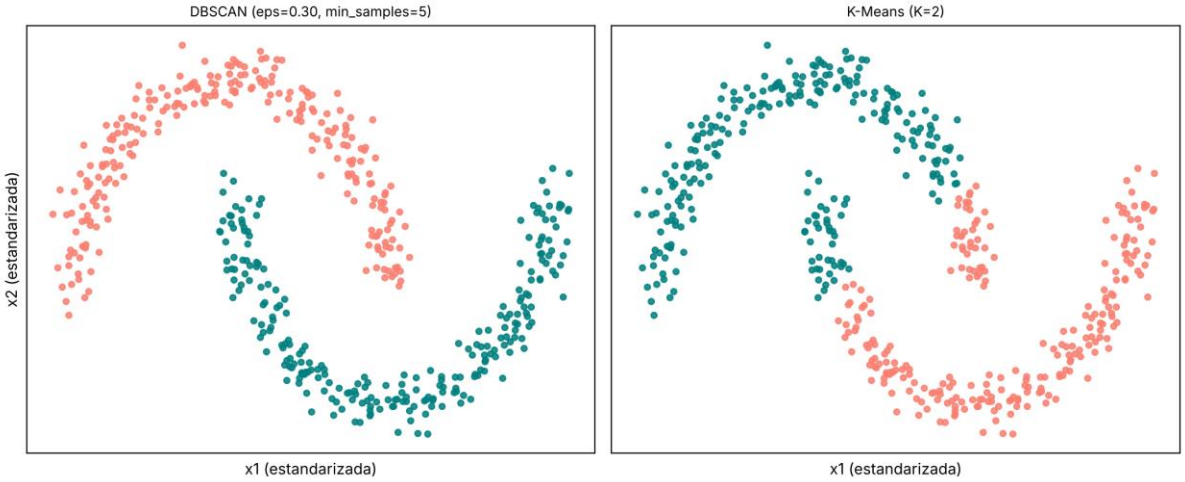
Efecto de eps y min_samples en DBSCAN



Nota. Las X negras son puntos de ruido (-1). Obtenido del notebook.

Se seleccionó `eps = 0,30` y `min_samples = 5`: produce dos clusters de 250 puntos y ningún punto de ruido, está dentro de la zona estable y, según el gráfico de k-distancias, 497 de los 500 puntos son centrales (los otros 3 son alcanzables desde un punto central). La Figura 6 la contrasta con K-Means (K = 2), que corta cada luna con una frontera recta. La Tabla 6 muestra cómo cambian las métricas según el tratamiento del ruido y la Tabla 7 compara ambos algoritmos.

Figura 6
DBSCAN seleccionado frente a K-Means (K = 2) en Make Moons



Nota. Los puntos de ruido, cuando existen, se muestran como X negras. Obtenido del notebook.

Tabla 6
Métricas de DBSCAN según el tratamiento del ruido

Configuración y tratamiento	Silhouette	Davies-Bouldin	Calinski-Harabasz
Seleccionada (eps = 0,30; min_samples = 5), sin ruido	0,386	1,022	433,9
eps = 0,20; min_samples = 5, ruido excluido	0,387	1,018	433,6
eps = 0,20; min_samples = 5, ruido como cluster	0,296	1,426	217,8

Nota. Con eps = 0,20 hay 4 puntos de ruido (0,8 %). Elaboración propia a partir de los resultados del notebook.

Tabla 7
DBSCAN frente a K-Means en Make Moons

Algoritmo	Silhouette	Davies-Bouldin	Calinski-Harabasz	ARI (ref.)
DBSCAN (eps=0,30, min_samples = 5)	0,386	1,022	433,9	1,000
K-Means (K=2)	0,494	0,812	693,8	0,445

Nota. Las métricas internas favorecen a K-Means aunque su agrupamiento no corresponde a la estructura real. Elaboración propia a partir de los resultados del notebook.

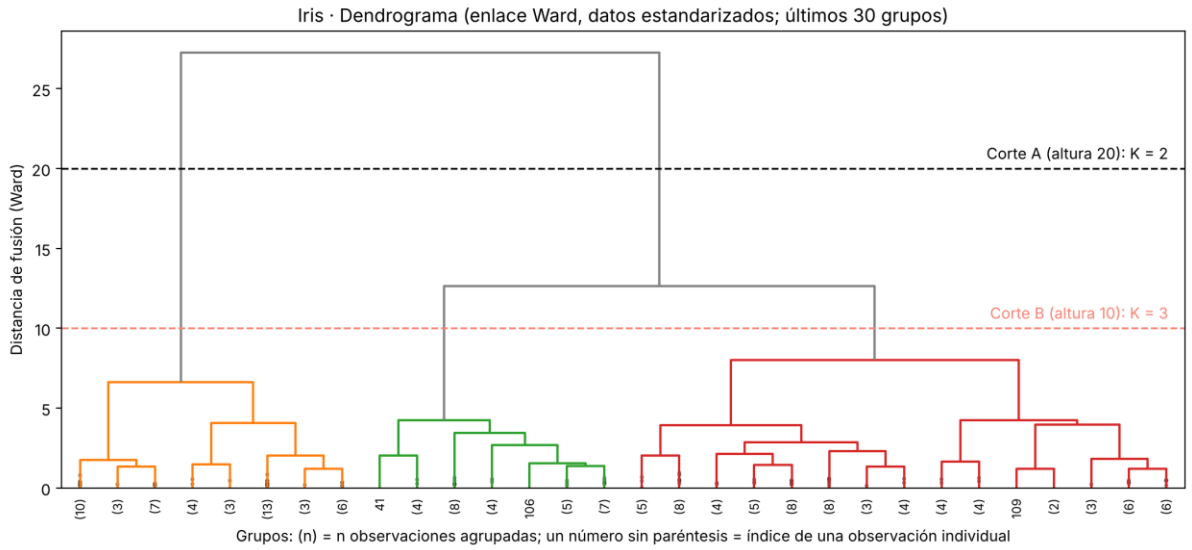
4.3 Clustering jerárquico sobre Iris

La Figura 7 presenta el dendrograma (enlace Ward, datos estandarizados); su correlación cofenética es de 0,823, de modo que conserva bien las distancias originales. La última fusión ocurre a una altura de 27,25 y la anterior a 12,64, un salto de 14,61, el mayor con diferencia;

cortar en cualquier altura entre esos dos valores produce dos clusters. El segundo salto (4,63) correspondería a tres clusters, y a partir de ahí ningún salto supera 2,36.

Figura 7

Dendrograma del clustering jerárquico en Iris (enlace Ward)



Nota. Se muestran los últimos 30 grupos; (n) indica n observaciones agrupadas y un número sin paréntesis es una observación individual. Las líneas punteadas son los cortes propuestos. Obtenido del notebook.

Tabla 8

Altura de corte y métricas internas según el número de clusters (Iris)

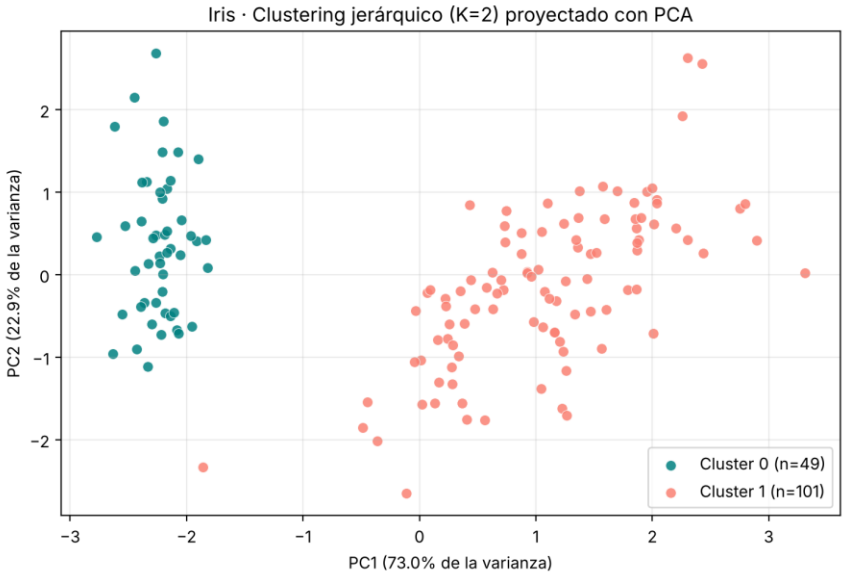
K	Rango de altura de corte	Amplitud	Silhouette	Davies-Bouldin	Calinski-Harabasz	ARI (ref.)
2	**12,64 – 27,25**	**14,61**	**0,577**	**0,592**	**240,2**	**0,544**
3	8,00 – 12,64	4,63	0,447	0,803	222,7	0,615
4	6,61 – 8,00	1,40	0,401	0,979	201,3	0,588
5	4,24 – 6,61	2,36	0,331	0,974	192,7	0,440
6	4,23 – 4,24	0,02	0,315	0,989	172,1	0,421

Nota. En negrita, el número de clusters seleccionado (K = 2). La amplitud es el ancho del intervalo de alturas que produce K clusters. El ARI es solo referencia. Elaboración propia a partir de los resultados del notebook.

Se propone cortar a una altura cercana a 20, es decir, **dos clusters**: es el salto más amplio del dendrograma y las tres métricas son mejores en K = 2 que en cualquier K mayor (Silhouette = 0,577; Davies-Bouldin = 0,592; Calinski-Harabasz = 240,2). Los clusters tienen 49 y 101 flores: el primero agrupa flores de pétalo muy pequeño (1,47 × 0,24 cm de media) y el segundo

flores de pétalo mayor (4,87 × 1,66 cm). La Figura 8 los proyecta con PCA, que conserva el 95,8 % de la varianza.

Figura 8
Clusters jerárquicos (K = 2) en Iris proyectados con PCA



Nota. El punto aislado del cluster 1 cerca del cluster 0 es la observación 41, una setosa atípica (ancho de sépalo de 2,3 cm). Obtenido del notebook.

Como análisis de sensibilidad se evaluó el segundo corte (K = 3, altura cercana a 10) y se comparó con K-Means (Tabla 9, Figura 9). K = 3 divide el cluster grande en dos subgrupos de 71 y 30 flores que se tocan, por lo que las métricas internas empeoran; frente a la especie real, K = 2 junta *versicolor* y *virginica* (ARI = 0,544) y K = 3 las separa en gran medida (ARI = 0,615). El jerárquico y K-Means con K = 3 dan resultados casi idénticos.

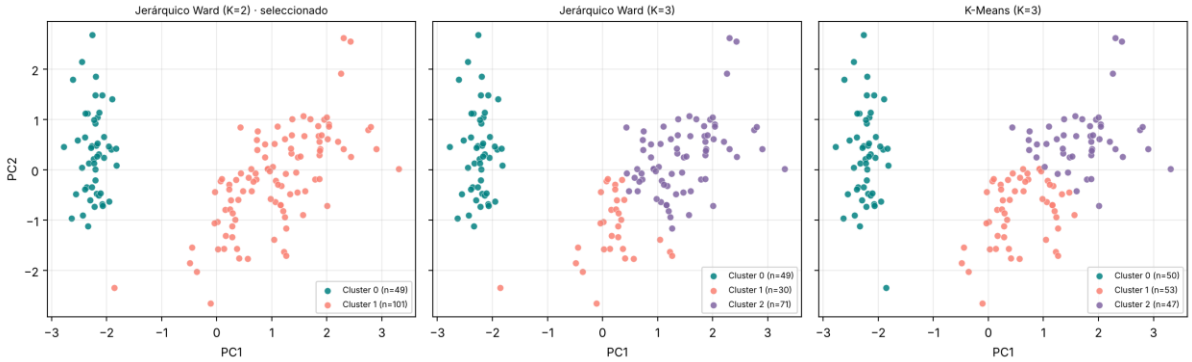
Tabla 9
Análisis de sensibilidad: jerárquico (K = 2 y K = 3) y K-Means (K = 3) en Iris

Modelo	Silhouette	Davies-Bouldin	Calinski-Harabasz	ARI (ref.)
Jerárquico Ward (K = 2), seleccionado	**0,577**	**0,592**	**240,2**	**0,544**
Jerárquico Ward (K = 3)	0,447	0,803	222,7	0,615
K-Means (K = 3)	0,460	0,834	241,9	0,620

Nota. Elaboración propia a partir de los resultados del notebook.

Figura 9

Comparación de K = 2 y K = 3 jerárquico y K-Means (K = 3) en Iris



Nota. Proyección PCA de los mismos datos con cada agrupamiento. Obtenido del notebook.

4.4 Comparación de los algoritmos

La Tabla 10 compara los tres algoritmos. Cada uno se aplicó a un conjunto distinto, por lo que los valores de las métricas **no son comparables entre columnas**: describen qué tan bien separó cada algoritmo su propio problema. Para contrastar algoritmos sobre el mismo dato se usaron las comparaciones de las Tablas 7 y 9.

Tabla 10
Comparación de K-Means, DBSCAN y clustering jerárquico

Aspecto	K-Means (Wine)	DBSCAN (Make Moons)	Jerárquico (Iris)
Forma de construir los grupos	Asigna cada punto al centroide más cercano y recalcula los centroides hasta converger	Une puntos densamente conectados (vecindad eps con al menos min_samples puntos)	Fusiona de forma sucesiva los dos grupos más cercanos (Ward) y se corta el dendrograma
Número de clusters obtenidos	3 (elegido con codo + Silhouette)	2 (más 0 puntos de ruido con la configuración elegida)	2 (corte a altura ≈ 20)
Hiperparámetros principales	K, n_init, init (distancia euclidiana)	eps, min_samples (distancia)	n_clusters o umbral de distancia, linkage (Ward), métrica
Silhouette Score	0,285	0,386	0,577
Davies-Bouldin Index	1,389	1,022	0,592
Calinski-Harabasz Score	70,9	433,9	240,2
Identifica ruido	No (todo punto se asigna a un cluster)	Sí (etiqueta -1; con eps=0,20 detecta 4 puntos)	No
Requiere definir previamente el número de clusters	Sí	No	No para construir el árbol; se decide al cortarlo
Principal ventaja	Rápido y escalable; simple de interpretar con centroides	Forma arbitraria de clusters y detección de ruido	Dendrograma: estructura a varios niveles, determinista
Principal limitación	Supone clusters convexos y de tamaño similar; sensible a escala y a la inicialización	Muy sensible a eps; falla con densidades distintas y en alta dimensión	Coste $O(n^2)$ en memoria; fusiones irreversibles; poco escalable

Nota. Las métricas corresponden a cada conjunto de datos y no son comparables entre columnas. Elaboración propia a partir de los resultados del notebook.

5. Análisis y discusión

5.1 K-Means (Wine)

- **Valor de K más apropiado.** K = 3: coinciden el codo (la reducción de inercia pasa de 381 a 103), el máximo del Silhouette (0,285) y de Calinski-Harabasz (70,94) y el mínimo de Davies-Bouldin (1,389).
- **¿Codo y Silhouette coinciden?** Sí. El codo es un criterio visual, porque la inercia siempre baja al aumentar K, mientras que el Silhouette sí tiene un máximo. Que ambos apunten a 3 da confianza, aunque la ventaja sobre K = 2 es moderada (Calinski-Harabasz de 70,9 frente a 69,5).

- **Qué indica la inercia.** La suma de distancias al cuadrado de las observaciones a su centroide, es decir, la cohesión interna. Con K = 3 es 1.277,9 frente a 2.314,0 con K = 1 (una reducción del 44,8 %). Por sí sola no sirve para elegir K porque siempre desciende al aumentar K.
- **Separación de los clusters.** Parcial. Los grupos son reconocibles en el plano PCA, pero el Silhouette (0,285) y Davies-Bouldin (1,389) indican una estructura moderada con solapamiento. El cluster 2 es el menos cohesionado (Silhouette medio de 0,177, frente a 0,343 y 0,351) y 7 de las 178 observaciones tienen silueta negativa.
- **Características que diferencian los grupos.** Flavonoides, fenoles totales, OD280/OD315, matiz, prolina, intensidad de color y alcohol. El cluster 0 (62 vinos) tiene prolina (≈ 1.100), flavonoides (3,00) y fenoles (2,85) altos; el cluster 1 (51), la mayor intensidad de color (7,23) y ácido málico (3,31) y los menores flavonoides (0,82); y el cluster 2 (65), el menor alcohol (12,25), color (2,97) y prolina (≈ 510).
- **Limitaciones.** K-Means supone grupos convexos y de tamaño similar y exige fijar K. Es sensible a la escala: sin estandarizar, el Silhouette sube a 0,571 pero el ARI cae de 0,897 a 0,371, porque la prolina domina la distancia. La estructura es moderada y PCA solo conserva el 55,4 % de la varianza, por lo que la gráfica simplifica los datos.

5.2 DBSCAN (Make Moons)

- **Si se disminuye demasiado eps.** La vecindad es tan pequeña que casi ningún punto alcanza la densidad mínima: con `eps = 0,05` el 95,2 % de los puntos es ruido y con 0,10 hay 24 clusters fragmentados.

- **Si eps aumenta.** Primero se completan los clusters correctos (dos clusters entre 0,20 y 0,40) y el ruido desaparece; después los clusters se fusionan: con 0,50 las dos lunas forman uno solo.
- **Función de min_samples.** Define cuántos vecinos debe haber dentro de `eps` para que un punto sea central, es decir, la exigencia de densidad. Valores mayores producen más ruido: con `eps = 0,30`, pasar de 5 a 20 genera 10 puntos de ruido (2,0 %).
- **Qué representa el ruido.** Observaciones en zonas de baja densidad no alcanzables desde ningún punto central. No son un grupo sino una señal: pueden ser atípicos reales, puntos de transición o extremos de una estructura, y conviene revisarlos.
- **Configuración más coherente.** `eps = 0,30` y `min_samples = 5`: dos clusters de 250 puntos, sin ruido y fieles a la forma de las lunas.
- **Por qué DBSCAN supera a K-Means aquí.** DBSCAN sigue regiones continuas de alta densidad sin suponer forma; K-Means asigna al centroide más cercano y genera regiones convexas con fronteras rectas (ARI de 0,445 frente a 1,000). Las métricas internas, que premian grupos compactos y redondeados, favorecen a K-Means (Silhouette de 0,494 frente a 0,386) aunque su resultado sea el equivocado.
- **Tratamiento del ruido en las métricas.** Tratar el ruido como un cluster penaliza injustamente el resultado (con `eps = 0,20`, el Silhouette baja de 0,387 a 0,296 y Calinski-Harabasz cae a la mitad). Por eso se excluye al calcular las métricas, pero se reporta siempre su porcentaje: con `eps = 0,05` el Silhouette más alto de la tabla (0,907) corresponde solo al 4,8 % de los puntos.

- **Ventajas y limitaciones.** No requiere fijar el número de clusters, encuentra formas arbitrarias e identifica ruido. Es muy sensible a `eps` (el rango útil aquí es acotado), no maneja bien densidades distintas ni alta dimensión, y sus métricas internas son difíciles de interpretar.

5.3 Clustering jerárquico (Iris)

- **Información del dendrograma.** Muestra cómo se fusionan los grupos y a qué distancia, de modo que revela la jerarquía completa y sugiere un número natural de clusters mediante los saltos de altura.
- **Punto de corte y número de clusters.** Una altura cercana a 20 (cualquier valor entre 12,64 y 27,25 da el mismo resultado), que produce **dos clusters** respaldados por las tres métricas. K = 3 (altura cercana a 10) es una alternativa defendible, pero con métricas peores (Silhouette de 0,447).
- **Separación.** Con K = 2 es clara (Silhouette de 0,577, con un hueco visible en un PCA que explica el 95,8 % de la varianza). Con K = 3, los dos subgrupos del cluster grande se solapan en su frontera.
- **Diferencias con K-Means.** El jerárquico no necesita fijar K de antemano, es determinista y entrega todas las soluciones anidadas; K-Means requiere K, depende de la inicialización y escala mucho mejor. Las fusiones del jerárquico son irreversibles y su coste crece al menos de forma cuadrática con n. Con K = 3 dieron resultados casi idénticos.
- **Ventajas de la representación jerárquica.** Permite explorar la estructura a varios niveles, comunicar visualmente las relaciones entre observaciones y elegir K con evidencia en lugar de suponerlo.

- **Honestidad metodológica.** La elección de K = 2 se basó solo en criterios no supervisados. Que Iris tenga tres especies es conocimiento externo: una métrica interna favorece K = 2 y la taxonomía favorece K = 3, y ambas lecturas responden preguntas distintas.

5.4 ¿En qué tipo de problema se usaría cada algoritmo?

- **K-Means.** Para segmentar grandes volúmenes de datos numéricos cuando se esperan grupos aproximadamente esféricos y de tamaño parecido y se puede estimar K, como la segmentación de clientes o la cuantización de colores. Se elige por su velocidad y porque los centroides se explican fácilmente; requiere estandarizar.
- **DBSCAN.** Para datos con formas irregulares, ruido o atípicos y número de grupos desconocido: datos geoespaciales, detección de anomalías o fraude (los puntos -1 son candidatos a revisión). Funciona mejor en pocas dimensiones y con densidades similares.
- **Clustering jerárquico.** Para conjuntos pequeños o medianos donde interesa la estructura a varios niveles o una taxonomía: genómica, agrupación de documentos o especies y análisis exploratorio para decidir cuántos segmentos considerar. No es apropiado para decenas de miles de observaciones por su coste cuadrático.

5.5 Limitaciones generales

Los conjuntos son pequeños y estándar, y las métricas no son comparables entre conjuntos distintos. PCA solo conserva el 55,4 % de la varianza en Wine. No se exploraron otras distancias, enlaces ni algoritmos (por ejemplo, mezclas gaussianas u OPTICS) ni se evaluó la estabilidad de DBSCAN y del jerárquico ante remuestreo. Los silhouettes de 0,29 a 0,58 se

interpretan como estructura de moderada a razonable según la regla práctica de Kaufman y Rousseeuw (1990), no como grupos perfectamente definidos.

6. Conclusiones

- **K-Means (Wine).** Con datos estandarizados, el codo y las tres métricas coinciden en K = 3. El modelo es estable, pero la estructura es moderada (Silhouette de 0,285). Los clusters se distinguen por flavonoides, fenoles, prolina, color y alcohol y coinciden en 172 de 178 muestras con los cultivares reales, que no se usaron para agrupar.
- **El preprocesamiento cambia el resultado.** Sin estandarizar, el Silhouette sube a 0,571 pero el ARI cae de 0,897 a 0,371: una métrica interna alta no implica clusters útiles.
- **DBSCAN (Make Moons).** `eps = 0,30` y `min_samples = 5` recuperan exactamente las dos lunas. El rango útil de `eps` es acotado: con 0,15 o menos la solución se fragmenta o se vuelve ruido y con 0,50 las lunas se fusionan.
- **Las métricas internas favorecen formas convexas.** K-Means obtuvo mejor Silhouette que DBSCAN en Make Moons (0,494 frente a 0,386) con un agrupamiento incorrecto. El ruido debe excluirse del cálculo y su porcentaje reportarse siempre.
- **Jerárquico (Iris).** El dendrograma tiene un salto dominante (14,61) y las tres métricas apuntan a K = 2 (Silhouette de 0,577); K = 3 es defendible desde el conocimiento externo y da un resultado casi idéntico al de K-Means.
- **Recomendación.** Elegir el algoritmo según la forma esperada de los grupos, la presencia de ruido y el tamaño de los datos, no según la métrica más alta; validar con varios criterios y siempre con visualización.

7. Repositorio GitHub

El código fuente, los datos de ejemplo y las figuras están disponibles en https://github.com/bravegn-arch/Guia_Semana_11_Clustering. La estructura es la siguiente:

```
/notebooks    Semana11_Clustering_Brayan_Vega.ipynb (los tres ejercicios y la comparación)
/data         wine.csv · moons.csv · iris.csv (datos de ejemplo)
/figures      figuras generadas por el notebook (PNG)
README.md     objetivo, algoritmos, datasets, estructura e instrucciones
requirements.txt
```

Para ejecutarlo: (1) clonar el repositorio; (2) instalar las dependencias con `pip install -r requirements.txt`; (3) abrir `notebooks/Semana11_Clustering_Brayan_Vega.ipynb` en Jupyter o Google Colab y ejecutar todas las celdas en orden. La semilla está fijada en 42 y las figuras se guardan en `/figures`.

8. Referencias

Caliński, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics, 3*(1), 1-27. https://doi.org/10.1080/03610927408827101

Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-1*(2), 224-227. https://doi.org/10.1109/TPAMI.1979.4766909

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. En *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)* (pp. 226-231). AAAI Press.

Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics, 7*(2), 179-188. https://doi.org/10.1111/j.1469-1809.1936.tb02137.x

Forina, M., Aeberhard, S., & Leardi, R. (1991). *Wine* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5PC7J

Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193-218. https://doi.org/10.1007/BF01908075

Kaufman, L., & Rousseeuw, P. J. (1990). *Finding groups in data: An introduction to cluster analysis*. Wiley. https://doi.org/10.1002/9780470316801

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. En L. M. Le Cam & J. Neyman (Eds.), *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* (Vol. 1, pp. 281-297). University of California Press.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825-2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53-65. https://doi.org/10.1016/0377-0427(87)90125-7

Scikit-learn. (s. f.). *Clustering*. https://scikit-learn.org/stable/modules/clustering.html

Universidad de Cundinamarca. (2026). *Ejercicios propuestos - Clustering (Semana 11)* [Guía de clase]. CADI Introducción a Machine Learning.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E.,

… SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261-272. https://doi.org/10.1038/s41592-019-0686-2

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236-244. https://doi.org/10.1080/01621459.1963.10500845

9. Anexos

Anexo A. Fragmentos de código clave

Se incluyen los fragmentos centrales del notebook. El código completo, con celdas separadas para carga de datos, limpieza, modelado y visualización, está en el repositorio.

A1. Funciones comunes: métricas internas, etiquetado estable y guardado de figuras

```
from sklearn.metrics import (silhouette_score, silhouette_samples,
                             davies_bouldin_score, calinski_harabasz_score,
                             adjusted_rand_score)


def metricas_internas(X, etiquetas, ignorar_ruido=True):
    """Calcula las tres métricas internas de validación de clustering.

    Parámetros
    ----------
    X : array (n, d)
        Datos con los que se construyeron los clusters (ya preprocesados).
    etiquetas : array (n,)
        Etiqueta de cluster de cada observación. El valor -1 es ruido (DBSCAN).
    ignorar_ruido : bool
        True  -> se excluyen los puntos -1 antes de calcular las métricas.
        False -> el ruido se trata como un cluster más (penaliza el resultado).

    Devuelve
    --------
    dict con Silhouette (mayor es mejor), Davies-Bouldin (menor es mejor) y
    Calinski-Harabasz (mayor es mejor). Si no hay al menos 2 clusters válidos,
    las métricas no están definidas y se devuelve NaN.
    """
    etiquetas = np.asarray(etiquetas)
    if ignorar_ruido:
        validos = etiquetas != -1
        X, etiquetas = X[validos], etiquetas[validos]
    n_clusters = len(np.unique(etiquetas))
    if n_clusters < 2 or n_clusters > len(etiquetas) - 1:
        return {"Silhouette": np.nan, "Davies-Bouldin": np.nan, "Calinski-Harabasz": np.nan}
    return {
        "Silhouette": silhouette_score(X, etiquetas),
        "Davies-Bouldin": davies_bouldin_score(X, etiquetas),
        "Calinski-Harabasz": calinski_harabasz_score(X, etiquetas),
    }



def reordenar_etiquetas(etiquetas, criterio, ascendente=False):
    """Renumera los clusters 0..k-1 ordenándolos por la media de `criterio`.

    Los algoritmos asignan números de cluster arbitrarios; con esta función el
    cluster 0 es siempre el de mayor (o menor) media de `criterio`.
    """
    etiquetas = np.asarray(etiquetas)
    medias =
pd.Series(np.asarray(criterio)).groupby(etiquetas).mean().sort_values(ascending=ascendente)
    mapa = {antiguo: nuevo for nuevo, antiguo in enumerate(medias.index)}
    return np.array([mapa[e] for e in etiquetas])



def guardar_figura(nombre):
    """Guarda la figura activa en /figures (PNG, 200 dpi) para usarla en el informe."""
```

```
    plt.savefig(os.path.join(FIG_DIR, nombre + ".png"), dpi=200, bbox_inches="tight")
```

A2. K-Means: inercia y métricas para K = 1 a 10

```
from sklearn.cluster import KMeans


filas = []
for k in range(1, 11):
    km = KMeans(n_clusters=k, n_init=10, random_state=SEED).fit(Xs_wine)
    fila = {"K": k, "Inercia": km.inertia_}
    if k >= 2:   # las métricas de silueta necesitan al menos 2 clusters
        fila.update(metricas_internas(Xs_wine, km.labels_))
    filas.append(fila)


tabla_k = pd.DataFrame(filas).set_index("K")
tabla_k["Reducción de inercia"] = -tabla_k["Inercia"].diff()   # cuánto baja la inercia al añadir
un cluster
tabla_k.round(4)
```

A3. DBSCAN: barrido de eps y min_samples

```
from sklearn.cluster import DBSCAN


configs = [(0.05, 5), (0.10, 5), (0.15, 5), (0.20, 5), (0.25, 5), (0.30, 5),
           (0.40, 5), (0.50, 5), (1.00, 5), (0.30, 3), (0.30, 20), (0.20, 10)]


filas, etiquetas_db = [], {}
for eps, ms in configs:
    lab = DBSCAN(eps=eps, min_samples=ms).fit_predict(Xs_moons)
    n_cl = len(set(lab)) - (1 if -1 in lab else 0)          # el -1 no es un cluster
    n_ruido = int((lab == -1).sum())
    filas.append({
        "eps": eps, "min_samples": ms, "Clusters": n_cl,
        "Ruido (n)": n_ruido, "Ruido (%)": round(100 * n_ruido / len(lab), 1),
        **metricas_internas(Xs_moons, lab, ignorar_ruido=True),
        "ARI (ref.)": adjusted_rand_score(y_moons, lab),
    })
    etiquetas_db[(eps, ms)] = lab


tabla_db = pd.DataFrame(filas)
tabla_db.round(3)
```

A4. Clustering jerárquico: enlace Ward y alturas de corte

```
from scipy.cluster.hierarchy import linkage, dendrogram, fcluster, cophenet
from scipy.spatial.distance import pdist


Z = linkage(Xs_iris, method="ward")                     # matriz de enlace (n-1 fusiones)
coef_cof = cophenet(Z, pdist(Xs_iris))[0]
print(f"Correlación cofenética (fidelidad del dendrograma a las distancias reales):
{coef_cof:.3f}")


# Alturas de las últimas fusiones: ¿qué corte deja un salto grande?
filas = []
for k in range(2, 9):
    h_sup = Z[-(k - 1), 2]      # altura de la fusión que reduce de k a k-1 clusters
    h_inf = Z[-k, 2]            # altura de la fusión anterior (de k+1 a k clusters)
    filas.append({"K": k, "Cortar entre (altura)": f"{h_inf:.2f} y {h_sup:.2f}", "Amplitud del
intervalo": h_sup - h_inf})
tabla_cortes = pd.DataFrame(filas).set_index("K")
tabla_cortes.round(2)
```

Anexo B. Resultados extendidos

Tabla B1

Inercia y métricas internas de K-Means en Wine para K = 1 a 10

K	Inercia	Reducción de inercia	Silhouette	Davies-Bouldin	Calinski-Harabasz
1	2.314,0	—	—	—	—
2	1.658,8	655,2	0,259	1,526	69,52
3	**1.277,9**	**380,8**	**0,285**	**1,389**	**70,94**
4	1.175,4	102,5	0,260	1,797	56,18
5	1.109,5	65,9	0,202	1,808	46,95
6	1.046,0	63,5	0,237	1,554	41,70
7	981,6	64,4	0,204	1,661	38,69
8	935,2	46,4	0,157	1,741	35,81
9	889,9	45,3	0,150	1,708	33,81
10	845,9	44,0	0,144	1,707	32,40

Nota. K = 1 solo sirve de referencia para la inercia. Elaboración propia a partir de los resultados del notebook.

Tabla B2

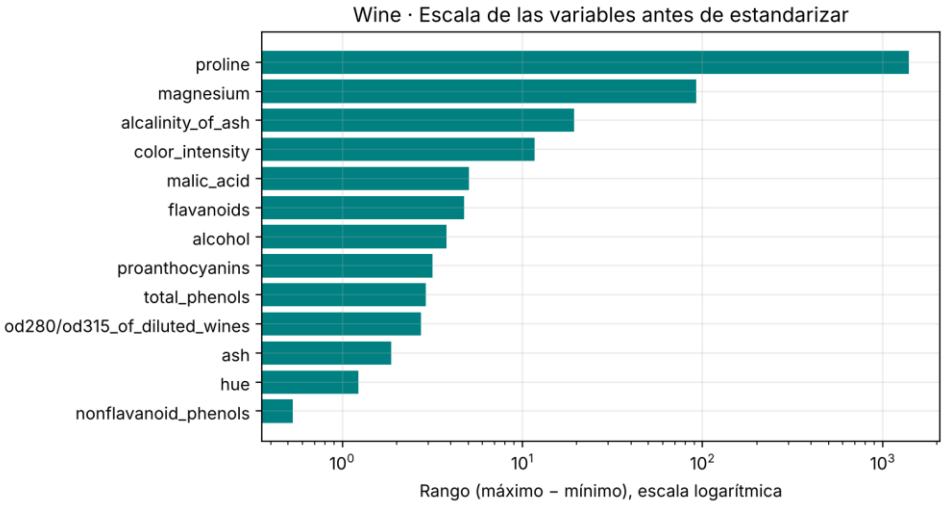
Efecto de no estandarizar en K-Means (Wine, K = 3)

Tratamiento	Silhouette	ARI (ref.)	Tamaños de los clusters
Con StandardScaler	0,285	0,897	[51, 62, 65]
Sin estandarizar	0,571	0,371	[47, 62, 69]

Nota. El Silhouette se calcula en el espacio en que se agrupó. Elaboración propia a partir de los resultados del notebook.

Figura B1

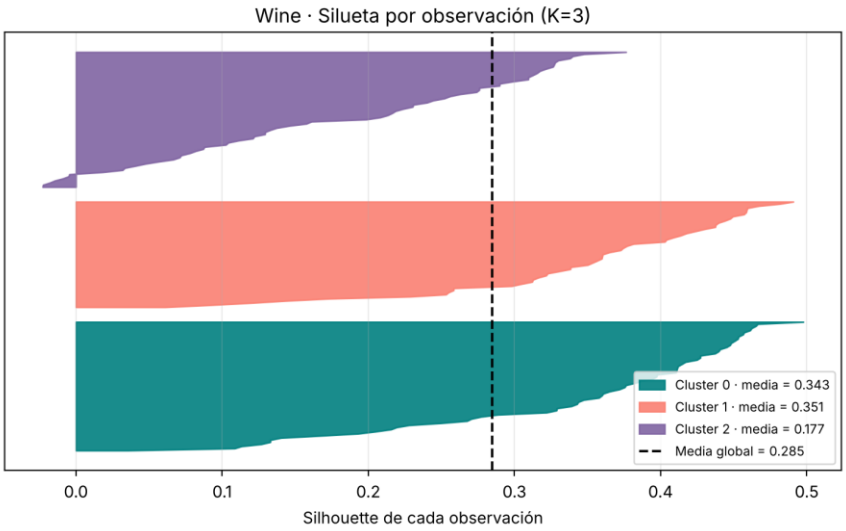
Escala de las variables de Wine antes de estandarizar



Nota. Rango (máximo menos mínimo) en escala logarítmica. Obtenido del notebook.

Figura B2

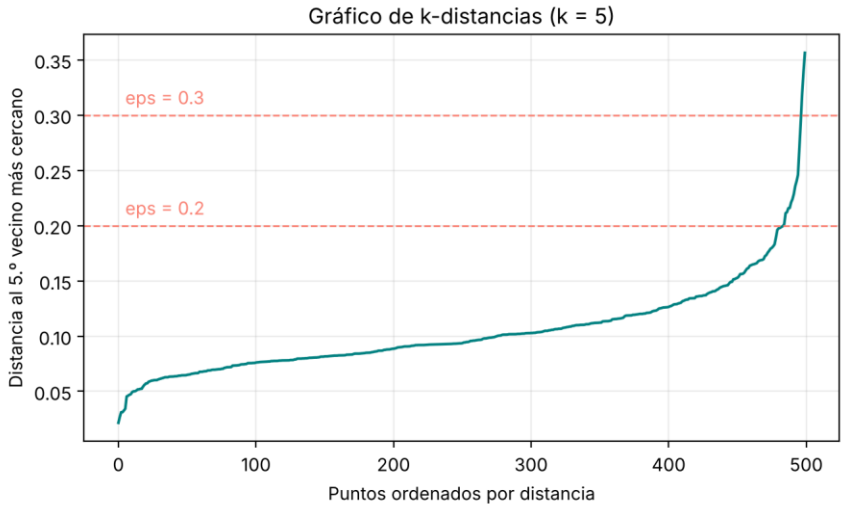
Silueta por observación de K-Means (K = 3) en Wine



Nota. La línea punteada es el Silhouette medio global (0,285). Obtenido del notebook.

Figura B3

Gráfico de k-distancias de Make Moons (k = 5)



Nota. Distancia de cada punto a su 5.º vecino más cercano, ordenada. Las líneas punteadas marcan eps = 0,20 y eps = 0,30. Obtenido del notebook.

Figura B4

Métricas internas del clustering jerárquico en Iris según K



Nota. Silhouette y Calinski-Harabasz: mayor es mejor; Davies-Bouldin: menor es mejor. Obtenido del notebook.